ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ ΜΥΕ002 - ΜΗΧΑΝΙΚΗ ΜΑΘΗΣΗ ΑΣΚΗΣΗ 2

Κίτσιος Κωνσταντίνος 4388 Λιόντος Αναστάσιος 4409

June 20, 2021

Contents

1	K-means clustering	3
2	Hierarchical clustering	7
3	K-medoids algorithm	12
4	Βοηθητική συνάρτηση histogram	16
5	Βοηθητική συνάρτηση reduce	16
6	Η βέλτιστη μέθοδος	16

1 K-means clustering

```
1 import idx2numpy as idx2numpy
2 import numpy as np
3 import Histogram
4 from sklearn.metrics import confusion_matrix
7 trainImagePath = "../dataset/train-images-idx3-ubyte"
8 trainLabelPath = "../dataset/train-labels-idx1-ubyte"
10 testImagePath = "../dataset/t10k-images-idx3-ubyte"
11 testLabelPath="../dataset/t10k-labels-idx1-ubyte"
13 x_train = idx2numpy.convert_from_file(trainImagePath)
14 y_train = idx2numpy.convert_from_file(trainLabelPath)
16 x_test = idx2numpy.convert_from_file(testImagePath)
17 y_test = idx2numpy.convert_from_file(testLabelPath)
19 x_train=x_train.reshape((x_train.shape[0], 28*28))
_{20} x_test=x_test.reshape((x_test.shape[0], 28*28))
21
22 x_train=x_train/255.0
23 x_test=x_test/255.0
24
25 k=10; # number of clusters
26 centroids = {}
27 def fit(data, distance):
      for i in range(k):
29
30
          centroids[i] = data[i]
31
      while(True):
32
33
          classifications = {}
34
35
          for i in range(k):
               classifications[i] = []
37
38
          for featureset in data:
               if (distance=='Euclidean'):
39
40
                   distances = [np.linalg.norm(featureset-
       centroids[centroid]) for centroid in centroids]
               elif (distance == 'Manhattan'):
41
                   distances = [np.linalg.norm(featureset -
       centroids[centroid], ord=1) for centroid in centroids
43
               elif (distance == 'Cosine'):
                   distances = []
44
45
                   for centroid in centroids:
                       dotP = np.dot(featureset, centroids[
46
       centroid].T)
                       if (isinstance(centroids[centroid],
       np.float64)):dotP = 0
48
                       norm1 = np.linalg.norm(featureset)
                       if (np.isnan(norm1).any()): norm1 =
49
       10**10
                       norm2 = np.linalg.norm(centroids[
       centroid])
                       if (np.isnan(norm2).any()): norm2 =
```

```
10**10
                       distances.append(dotP/(norm2*norm1))
53
54
55
               minn=np.amin(distances)
56
57
               classification = distances.index(minn)
               classifications[classification].append(
58
       featureset)
           prev_centroids = dict(centroids)
60
61
62
           for classification in classifications:
               centroids[classification] = np.average(
63
       classifications[classification],axis=0)
64
65
           optimized = True
66
          for c in centroids:
67
68
              original_centroid = prev_centroids[c]
               current_centroid = centroids[c]
69
70
              if np.sum((current_centroid-original_centroid
       )/original_centroid*100.0) > 0.001:
                  optimized = False
71
72
73
          if optimized:
74
              break
75
76 def predict(data):
77
       classification = []
78
       for d in data:
          distances = [np.linalg.norm(d-centroids[centroid
79
       ]) for centroid in centroids]
          classification.append(distances.index(min(
80
       distances)))
      return classification
81
82
83 def purity(y_true,y_pred):
         np.seterr(divide='ignore', invalid='ignore')
84
85
          cm = confusion_matrix(y_true, y_pred, labels=[i
       for i in range(10)])
          return np.sum(np.amax(cm,axis=0)) / np.sum(cm)
86
88 def f_measure(y_true,y_pred):
       np.seterr(divide='ignore', invalid='ignore')
89
       cm = confusion_matrix(y_true, y_pred, labels=[i for i
       in range(10)])
       tp = np.diag(cm)
      fp=cm.sum(axis=0) - np.diag(cm)
92
      fn = cm.sum(axis=1) - np.diag(cm)
93
       tn=cm.sum()-(tp+fn+fp)
94
      recall = tp/(tp+fn)
95
       precision = tp/(tp+fp)
       f1 = 2*((precision*recall)/(precision+recall))
97
98
       f1[np.isnan(f1)] = 0
      return f1.sum()
100 print ("-----Kmeans clustering
       algorithm----")
101 print("#################R1-Data Represantation
       ###########"")
102 fit(x_train, "Euclidean")
```

```
103 classes = predict(y_test)
104 print("-----")
print("Purity score {:.3f}%".format(purity(y_test,np.
      array(classes))*100))
106 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(classes))*100))
107 fit(x_train, "Manhattan")
108 classes = predict(y_test)
109 print("-----")
110 print("Purity score {:.3f}%".format(purity(y_test,np.
      array(classes))*100))
111 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(classes))*100))
112 fit(x_train, "Cosine")
113 classes = predict(y_test)
114 print("-----")
print("Purity score {:.3f}%".format(purity(y_test,np.
      array(classes))*100))
116 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(classes))*100))
117
118 print("##################R2-Data Represantation
      #############"")
119
120 histArray=Histogram.histogram(x_train,32)
121 testhistArray=Histogram.histogram(x_test,32)
122
123 fit(histArray, "Euclidean")
{\tt 124} \ {\tt clusters=predict(testhistArray)}
125 print("-----")
126 print("Purity score {:.3f}%".format(purity(y_test,np.
      array(clusters))*100))
127 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(clusters))*100))
129 fit(histArray, "Manhattan")
130 clusters=predict(testhistArray)
131 print("-----")
print("Purity score {:.3f}%".format(purity(y_test,np.
      array(clusters))*100))
133 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(clusters))*100))
135 fit(histArray, "Cosine")
136 clusters=predict(testhistArray)
137 print("----")
138 print("Purity score {:.3f}%".format(purity(y_test,np.
      array(clusters))*100))
139 print("F-measure score {:.3f}%".format(f_measure(y_true=
      y_test, y_pred=np.array(clusters))*100))
```

Αρχικά, αρχικοποιούμε τα κέντρα επιλέγοντας τις πρώτες k είκονες από το σύνολο δεδομένων. Στη συνέχεια, για κάθε πρότυπο, βρίσκουμε ποιο κέντρο βρίσκεται πιο κόντα σε αυτό το πρότυπο με βάση μία από τις τρεις συναρτήσεις απόστασης και το τοποθετούμε στη συστάδα του κέντρου αυτού. Έπειτα, ενημερώνουμε την τιμή κάθε κέντρου, θέτοντάς το ίσο με τη μέση τιμή των προτύπων που ανήκουν στη συστάδα του κέντρου αυτού, επαναλαμβάνοντας αυτή τη διαδικασία εώς ότου να μην υπάρχει αλλαγή στα κέντρα C_k . Τα αποτελέσματα της μεθόδου K-means

για τις ζητούμενες αποστάσεις και τις ζητούμενες αναπαραστάσεις των δεδομένων είναι τα εξής:

Kmeans clustering algorithm
######################################
Purity score 20.000%
F-measure score 20.000%
——————————————————————————————————————
Purity score 20.000%
·
F-measure score 20.000%
Cosine
Purity score 10.000%
F-measure score 18.182%
###############R2-Data Represantation####################################
Euclidean
Purity score 31.020%
F-measure score 75.881%
Manhattan
Purity score 27.990%
F-measure score 80.428%
Cosine
Purity score 10.000%
F-measure score 18.182%

2 Hierarchical clustering

```
1 import math
2 from sklearn.metrics import confusion_matrix
3 import numpy as np
{\tt 4} \quad {\tt import} \quad {\tt idx2numpy} \quad {\tt as} \quad {\tt idx2numpy}
5 import Histogram, ReduceDataSet
8 class Hierarchical:
   def __init__(self,data):
    ,,,
10
      constructor of the class, it takes the main data
11
      frame as input
12
      self.data = data
13
14
      self.n_samples, self.n_features = data.shape
15
    def DistanceMatrix(self,data,distance):
16
17
      arguement
18
19
      data - the dataset whose Similarity matrix we are
20
       going to calculate
21
      returns
22
23
      the distance matrix.
      N = len(data)
25
      if (distance == "Cosine"):
26
        similarity_mat = np.ones([N, N]) #for cosine np.
27
        similarity_mat = np.zeros([N, N]) #for cosine np.
29
30
      for i in range(N):
31
       for j in range(N):
          similarity_mat[i][j]=self.SimilarityMeasure(data[
       i],data[j],distance)
33
      return similarity_mat
34
     def SimilarityMeasure(self,data1, data2, distance):
35
36
37
      arguements
38
      data1, data2 - vectors, between which we are going to
39
        calculate similarity
      returns
41
42
      distance between the two vectors
43
      N=self.n_features
44
45
       if distance=='Euclidean':
       # for L2 norm or pythagorean distance
46
47
        dist = 0
        for i in range(N):
48
          dist += (data1[i] - data2[i])**2
49
        dist = math.sqrt(dist)
51
52
         return dist
```

```
53
54
      if distance=='Cosine':
        # form cosine similarity = a.b/|a|.|b|
55
56
        dot_prod = 0
57
        data1_mod = np.linalg.norm(data1)
        data2_mod = np.linalg.norm(data2)
58
59
        for x in range(N):
          dot_prod += data1[x]*data2[x]
60
61
        return (1-dot_prod/(data1_mod*data2_mod))
62
      if distance == 'Manhattan':
63
64
        # for L1 norm or pythagorean distance
65
        dist = 0
        for i in range(N):
66
67
          dist += abs(data1[i] - data2[i] )
        return dist
68
69
     def fit(self,k,distance):
70
71
72
      this method uses the main Divisive Analysis algorithm
       to do the clustering
73
      arguements
74
      k - integer
75
76
             number of clusters we want
77
78
      returns
79
       cluster_labels - numpy array
80
               an array where cluster number of a sample
       corrosponding to
82
                the same index is stored
83
      similarity_matrix = self.DistanceMatrix(self.data,
84
       distance) # similarity matrix of the data
       clusters = [list(range(self.n_samples))]
       of clusters, initially the whole dataset is a single
       cluster
      while True:
86
        c_diameters = [np.max(similarity_matrix[cluster][:,
        cluster]) if (len(similarity_matrix[cluster][:,
       cluster]) != 0) else -1 for cluster in clusters] #
       cluster diameters
        max_cluster_dia = np.argmax(c_diameters) #maximum
88
       cluster diameter
        max_difference_index = np.argmax(np.mean(
       similarity_matrix[clusters[max_cluster_dia]][:,
       clusters[max_cluster_dia]], axis=1))
        splinters = [clusters[max_cluster_dia][
90
       max_difference_index]] #spinter group
        last_clusters = clusters[max_cluster_dia]
91
        del last_clusters[max_difference_index]
92
        while True:
94
           split = False
95
           for j in range(len(last_clusters))[::-1]:
            splinter_distances = similarity_matrix[
       last_clusters[j], splinters]
            last_distances = similarity_matrix[
       last_clusters[j], np.delete(last_clusters, j, axis=0)
             if np.mean(splinter_distances) <= np.mean(</pre>
```

```
last_distances):
99
                splinters.append(last_clusters[j])
                del last_clusters[j]
100
                split = True
101
102
                break
            if split == False:
103
104
              break
105
          del clusters[max_cluster_dia]
106
          clusters.append(splinters)
107
          clusters.append(last_clusters)
108
         if len(clusters) == k:
109
            break
110
       cluster_labels = np.zeros(self.n_samples)
112
       for i in range(len(clusters)):
         cluster_labels[clusters[i]] = i
113
114
       return (clusters, cluster_labels)
115
116
117
     def purity(self,y_true,y_pred):
118
119
       np.seterr(divide='ignore', invalid='ignore')
        cm = confusion_matrix(y_true, y_pred, labels=[i for i
120
         in range(10)])
121
       return np.sum(np.amax(cm,axis=0)) / np.sum(cm)
122
123
     def f_measure(self,y_true,y_pred):
       np.seterr(divide='ignore', invalid='ignore')
124
       {\tt cm = confusion\_matrix(y\_true, y\_pred, labels=[i \  \, \textbf{for} \  \, i \  \, }
125
        in range(10)])
       tp = np.diag(cm)
126
       fp=cm.sum(axis=0) - np.diag(cm)
127
       fn = cm.sum(axis=1) - np.diag(cm)
128
       tn=cm.sum()-(tp+fn+fp)
129
       recall = tp/(tp+fn)
130
131
       precision = tp/(tp+fp)
       f1 = 2*((precision*recall)/(precision+recall))
132
133
       f1[np.isnan(f1)] = 0
       return f1.sum()
134
135
136
137 trainImagePath = "../dataset/train-images-idx3-ubyte"
138 trainLabelPath = "../dataset/train-labels-idx1-ubyte"
139 testImagePath = "../dataset/t10k-images-idx3-ubyte"
140 testLabelPath="../dataset/t10k-labels-idx1-ubyte"
141
142 x_train = idx2numpy.convert_from_file(trainImagePath)
143 x_test = idx2numpy.convert_from_file(testImagePath)
144
145 y_train = idx2numpy.convert_from_file(trainLabelPath)
146 y_test = idx2numpy.convert_from_file(testLabelPath)
147
148 x_train=x_train.reshape((x_train.shape[0], 28*28))
149 x_test=x_test.reshape((x_test.shape[0], 28*28))
150
151
153
154 Hx_train, Hy_train = ReduceDataSet.reduce(x_train,y_train
        ,10,5000)
```

```
156
157 histArray=Histogram.histogram(Hx_train,16)
158
159 print ("------Hierarchical clustering
       algorithm-----")
160
161 print("#################R2-Data Represantation
      ############"")
162 Hmodel = Hierarchical(histArray)
164 print("-----")
165 Hclusters, Hlabels = Hmodel.fit(10, "Euclidean")
166 print("Purity score {:.3f}%".format(Hmodel.purity(y_true=
      Hy_train, y_pred=Hlabels)*100))
167 print("F-measure score {:.3f}%".format(Hmodel.f_measure(
      y_true=Hy_train, y_pred=Hlabels)*100))
168
169 print("-----")
170 Hclusters, Hlabels = Hmodel.fit(10, "Manhattan")
171 print("Purity score {:.3f}%".format(Hmodel.purity(y_true=
      Hy_train, y_pred=Hlabels)*100))
172 print("F-measure score {:.3f}%".format(Hmodel.f_measure(
      y_true=Hy_train, y_pred=Hlabels)*100))
173
174 print("----")
175 Hclusters, Hlabels = Hmodel.fit(10, "Cosine")
176 print("Purity score {:.3f}%".format(Hmodel.purity(y_true=
       {\tt Hy\_train}\;,\;\;{\tt y\_pred=Hlabels)*100)})
177 print("F-measure score \{:.3f\}\%".format(Hmodel.f_measure(
      y_true=Hy_train, y_pred=Hlabels)*100))
178
179 print("##################R1-Data Represantation
       ############"")
180
181
182 x_train, y_train = ReduceDataSet.reduce(x_train,y_train
      ,10,2000)
183 x_train=x_train/255.0
184
185 model = Hierarchical(x_train)
186
187 print("-----")
188 clusters, labels = model.fit(10, "Euclidean")
189 print("Purity score {:.3f}%".format(model.purity(y_true=
       y_train, y_pred=labels)*100))
190 print("F-measure score {:.3f}%".format(model.f_measure(
      y_true=y_train, y_pred=labels)*100))
192 print("-----")
193 clusters, labels = model.fit(10, "Manhattan")
194 print("Purity score {:.3f}%".format(model.purity(y_true=
      y_train, y_pred=labels)*100))
195 print("F-measure score {:.3f}%".format(model.f_measure(
      y_true=y_train, y_pred=labels)*100))
197 print("-----")
198 clusters, labels = model.fit(10, "Cosine")
199 print("Purity score {:.3f}%".format(model.purity(y_true=
      y_train, y_pred=labels)*100))
200 print("F-measure score {:.3f}%".format(model.f_measure(
      y_true=y_train, y_pred=labels)*100))
```

Αρχικά, ξεκινάμε με όλα τα σημεία σε μία συστάδα, η οποία στη συνέχεια, χωρίζεται σε δύο λιγότερο όμοιες συστάδες. Υπολογίζουμε τον distance matrix C(i,j), ο οποίος αναπαριστά τις αποστάσεις των σημείων i,j (σύμφωνα με κάποια από τις τρεις συναρτήσεις απόστασης.) Έπειτα, η συστάδα διασπάται με βάση τη μεγαλύτερη μέση απόσταση σε δύο νέες συστάδες και τα εναπομέιναντα σημεία μετακινούνται, εάν η διαφορά μεταξύ της μέσης απόστασης και της απόστασης με την άλλη συστάδα είναι θετική. Στη συνέχεια, υπολογίζουμε τη διάμετρο της κάθε συστάδας, η οποία ορίζεται ως η απόσταση μεταξύ δύο οποιονδήποτε σημείων της συστάδας και επιλέγεται η συστάδα με τη μεγαλύτερη διάμετρο για περαιτέρω διάσπαση. Η παραπάνω διαδικασία, επαναλαμβάνεται έως ότου πάρουμε τον επιθυμητό αριθμό συστάδων. Τα αποτελέσματα του Hierarchical clustering για τις ζητούμενες αναπαραστάσεις των δεδομένων είναι τα εξής:

Hierarchical clustering algorithm	
############################R2-Data Represantation####################################	#
Purity score 28.240%	
F-measure score 12.355%	
Manhattan	
Purity score 26.260%	
F-measure score 42.998%	
Cosine	
Purity score 29.480%	
F-measure score 74.590%	
#####################R1-Data Represantation####################################	#
Euclidean	
Purity score 47.400%	
F-measure score 79.292%	
Manhattan	
Purity score 43.300%	
F-measure score 98.818%	
Cosine	
Purity score 40.150%	
F-measure score 98 405%	

3 K-medoids algorithm

```
1 import numpy as np
2 from math import log2
3 from sklearn.metrics import confusion_matrix
4 import idx2numpy as idx2numpy
5 import Histogram, ReduceDataSet
8 class k_medoids:
      def __init__(self, k=10): # total number of clusters
       =10
           self.k = k
12
      def fit(self, data):
13
14
           # For 1st clustering
           self.medoids = []
15
           self.cost = 0
16
17
           self.clusters = []
           for i in range(self.k):
18
              self.medoids.append(data[i]) # selecting k
19
       random points out of the dataset as the medoids (1st
       step)
20
           for j in range(self.k):
21
               self.clusters.append([])
22
           for point in data:
               # list containing distances of each point in
24
       the dataset from the medoids and finding minimum
       distance
25
               distance = [np.sum(np.where(point != 0, point
        * np.log(point / m), 0)) for m in self.medoids]
27
               min_distance = min(distance)
               # calculating the cost (cost is the distance
28
       of each point from its medoid i.e., total of min
       distances)
               self.cost += min_distance
29
30
               o = distance.index(min_distance)
               # clustering (i.e., associating each point to
31
        the closest medoid)
               self.clusters[o].append(point)
32
33
34
           # now, at each iteration we are finding the
       replacement of our medoids
           \mbox{\tt\#} we will stop if there is no changes in the cost
36
           while (True):
37
               # lists that will store new clusters, new
38
       cost and the new medoids
               new_clusters = []
39
40
               self.new_cost = 0
               self.new_medoids = []
41
42
               for j in range(self.k):
43
                   new_clusters.append([])
44
               for j in range(self.k):
                   # list for storing the total distance of
       a particular point from all other points in the same
```

```
cluster
47
                   dist_with_each_point_in_same_cluster = []
                   1 = [] # list for storing the distance
48
       of each and every point from all other points of the
       same cluster
49
50
                   for point in self.clusters[j]:
                       dist_with_each_point_in_same_cluster
51
       = sum([np.sum(np.where(point != 0, point * np.log(
       point / d), 0)) for d in self.clusters[j]])
                       1.append(
52
       dist_with_each_point_in_same_cluster)
                   minima = min(1) # finding the minimum
       distance
54
                   q = 1.index(minima)
                   # point with the min distance from all
55
       the points in the same cluster is taken as the new
       medoid
                   self.new_medoids.append(self.clusters[j][
56
       q])
57
58
                   # now, finding the new clustering and the
        new cost
60
               for point in data:
                   # list containing distances of each point
61
        in the dataset from the new medoids and finding
       minimum distance
                   distance = [np.sum(np.where(point != 0,
62
       point * np.log(point / m), 0)) for m in self.
       new_medoids]
                   min_distance = min(distance)
63
                   # calculating the new cost
64
                   self.new_cost += min_distance
65
66
                   o = distance.index(min_distance)
67
                   # new clustering
                   new_clusters[o].append(point)
68
               # if the cost decreases with the new medoids
70
       we will replace the old medoids, old clusters and the
        old cost with the new one
               # if the cost increases with the new medoids
       we will not replace the old medoids, old clusters and
        the oldcost with the new one
72
73
               if self.new_cost < self.cost:</pre>
                   self.medoids = self.new_medoids
74
75
                   self.clusters = new_clusters
                   self.cost = self.new_cost
76
77
78
               # if the cost remains same we will stop and
       come out of the iterations
79
               elif abs(self.new_cost - self.cost) <= 0.01:</pre>
80
81
                   break
82
      # final clustering according to the new medoids
83
84
       def predict(self, test_data):
           pred = []
85
86
           for point in test_data:
               # finding distance of each point from the
```

```
final medoids and get the min distance
               distance = [np.sum(np.where(point != 0, point
         * np.log(point / m), 0)) for m in self.medoids]
               minDistance = min(distance)
89
               1 = distance.index(minDistance)
               pred.append(1) # associating each point to
91
       the closest medoid
           return pred
92
93
       def purity(self, y_true, y_pred):
94
           np.seterr(divide='ignore', invalid='ignore')
95
96
           cm = confusion_matrix(y_true, y_pred, labels=[i
       for i in range(10)])
           return np.sum(np.amax(cm, axis=0)) / np.sum(cm)
97
98
       def f_measure(self, y_true, y_pred):
99
           np.seterr(divide='ignore', invalid='ignore')
100
           cm = confusion_matrix(y_true, y_pred, labels=[i
101
       for i in range (10)])
102
           tp = np.diag(cm)
           fp = cm.sum(axis=0) - np.diag(cm)
103
           fn = cm.sum(axis=1) - np.diag(cm)
104
           tn = cm.sum() - (tp + fn + fp)
105
           recall = tp / (tp + fn)
106
107
           precision = tp / (tp + fp)
           f1 = 2 * ((precision * recall) / (precision +
108
       recall))
           f1[np.isnan(f1)] = 0
           return f1.sum()
110
112
113 trainImagePath = "../dataset/train-images-idx3-ubyte"
114 trainLabelPath = "../dataset/train-labels-idx1-ubyte"
testImagePath = "../dataset/t10k-images-idx3-ubyte"
116 testLabelPath = "../dataset/t10k-labels-idx1-ubyte"
117
118 x_train = idx2numpy.convert_from_file(trainImagePath)
119 x_test = idx2numpy.convert_from_file(testImagePath)
120
121 y_train = idx2numpy.convert_from_file(trainLabelPath)
122 y_test = idx2numpy.convert_from_file(testLabelPath)
124 x_train = x_train.reshape((x_train.shape[0], 28 * 28))
x_{\text{test}} = x_{\text{test.reshape}}((x_{\text{test.shape}}[0], 28 * 28))
126
127 x_train, y_train = ReduceDataSet.reduce(x_train, y_train
        ,10,6000)
128 print(x_train.shape)
129 bins = 16
130 histArray = Histogram.histogram(x_train,bins)
131 testhistArray=Histogram.histogram(x_test,bins)
132
133 model = k_medoids()
134 model.fit(histArray)
135 clusters = model.predict(testhistArray)
137 print ("-----Kmedoid clustering
       algorithm-----")
138 print("#################R2-Data Represantation
       ###########"")
139 print("Purity score {:.3f}%".format(model.purity(y_true=
```

Αρχικά, αρχικοποιούμε τις διαμέσους (medoids) επιλέγοντας τις πρώτες ${\bf k}$ είκονες από το σύνολο δεδομένων. Στη συνέχεια, για κάθε πρότυπο, βρίσκουμε ποιο medoid είναι περισσότερο όμοιο σε αυτό το πρότυπο με βάση την symmetric Kullback-Libler distance και το τοποθετούμε στη συστάδα του medoid αυτού. Έπειτα, ενημερώνουμε την τιμή κάθε medoid, θέτοντάς το ίσο με το σημείο του cluster που έχει τη μεγαλύτερη ομοιότητα με όλα τα υπόλοιπα σημεία, επαναλαμβάνοντας αυτή τη διαδικασία εώς ότου να μην υπάρχει αλλαγή στα κέντρα C_k . Τα αποτελέσματα της μεθόδου K-medoids είναι τα εξής:

4 Βοηθητική συνάρτηση histogram

```
import numpy as np
def histogram(X,bins):
   histArray=[]
for i in X:
   histArray.append(np.array(np.histogram(i,bins)[0]))
return np.array(histArray, dtype='float64')
```

Η συνάρτηση histogram που βρίσκεται στο αρχείο Histogram.py παίρνει ως όρισμα ένα dataset και τον αριθμό των bins που επιθυμούμε και δημιουργεί το τελικό dataset που περιέχει το ιστόγραμμα της κάθε εικόνας.

5 Βοηθητική συνάρτηση reduce

Η συνάρτηση reduce που βρίσκεται στο αρχείο ReduceDataSet.py παίρνει ως όρισμα ένα dataset μαζί με τα labels, το πλήθος των κλάσεων και τέλος τον αριθμό των στοιχείων που θα έχει το μειωμένο (τελικό) dataset. Για κάθε κατηγορία, υπολογίζουμε το πλήθος των στοιχείων που θα έχει αυτή η κατηγορία και έπειτα τα τοποθετούμε στο τελικό dataset.

6 Η βέλτιστη μέθοδος

Επειτα από σύγκριση των μέτρων αξιολόγησης Purity, F-measure καταλήγουμε πως η βέλτιση μέθοδος για την R_1 αναπαράσταση δεδομένων είναι η μέθοδος της ιεραρχικής συσταδοποίησης με χρήση της ευκλείδιας απόστασης καθώς έχει το μεγαλύτερο Purity (47.4%) και για την R_2 αναπαράσταση δεδομένων είναι η μέθοδος της ιεραρχικής συσταδοποίησης με χρήση της συνημιτονοειδούς απόστασης καθώς έχει το μεγαλύτερο Purity (29.48%).